

FACIAL STROKE EARLY SIGN DETECTION

TIM PENGEMBANG / DEVELOPER:

ID Anggota	Nama Lengkap	Peran / Role	Status
CACC180D6Y0517	Muhammad Taffarel Al Ghazali	AI Engineer	Aktif
CACC180D6Y2557	Kelana Patradewa Rahira Latif	AI Engineer	Aktif
CDCC889D6X0676	Anggita Puspitaningrum	Data Scientist	Aktif
CDCC889D6X0677	Salma Alya Sabila	Data Scientist	Aktif
CFCC332D6X1479	Safira Aulianisa	Full-Stack Web Developer	Aktif
CFCC332D6X0685	Handika Cahya Wulandari	Full-Stack Web Developer	Aktif

Kategori Tugas: Healthy Lives & Well-being
Komponen Berkas: Data Non Citra

BAB 1: PENDAHULUAN & PERUMUSAN MASALAH BISNIS

Rubrik Keselarasan: Harus menyertakan Latar Belakang dan Business Questions yang terukur untuk data klinis dan pencitraan.

Stroke tetap menduduki peringkat atas komorbiditas mematikan yang menuntut penanganan preventif berbasis data terukur. Akurasi penaksiran risiko tidak dapat dicapai secara optimal apabila hanya mengandalkan rekam medis teks saja, ataupun gambar pindaian saja. Oleh karena itu, proyek ini menerapkan pendekatan Multimodal Data Analytics dengan meleburkan parameter klinis internal pasien (data tabular) dan bukti struktural fisik jaringan otak (data citra).

Guna memenuhi kriteria ketepatan arah analisis, proyek ini dikendalikan oleh lima rumusan pertanyaan bisnis operasional:

1. Bagaimana kuantifikasi tingkat ketidakseimbangan kelas target (class imbalance) pada distribusi data riwayat kesehatan awal?
2. Variabel klinis apa saja yang secara statistik bertindak sebagai stimulan atau faktor risiko dengan asosiasi positif terkuat terhadap kejadian stroke?
3. Apakah terdapat interaksi korelasi linier yang signifikan secara biner antara variabel penuaan (usia), hipertensi, dan kerusakan pembuluh darah jantung?
4. Bagaimana karakteristik sebaran silang antara indikator biokimia (rata-rata kadar glukosa darah) dan antropometri (BMI) dalam memisahkan klaster pasien stroke?
5. Bagaimana merancang pipeline transformasi fitur dan prapemrosesan yang mutlak bersih dari risiko kebocoran data (data leakage) untuk menjamin validitas model klasifikasi akhir?

BAB 2: DATA UNDERSTANDING & DATA DICTIONARY

Rubrik Keselarasan: Wajib melampirkan Data Dictionary (Kamus Data) formal yang mencakup seluruh fitur yang dipakai dalam rekayasa data.

2.1 Kamus Data Non-Citra (Data Rekam Medis Tabular)

Nama Fitur / Kolom	Tipe Data Statistika	Deskripsi Bisnis Variabel	Format Nilai / Kode
Gender	Kategorikal (Nominal)	Jenis kelamin biologis pasien pemeriksaan.	0: Female, 1: Male
Age	Numerik (Diskrit)	Usia pasien terhitung dalam satuan tahun.	Angka bulat (18 - 90)
Hypertension	Kategorikal (Biner)	Status diagnosis riwayat penyakit tekanan darah tinggi.	0: Tidak Ada, 1: Ada
Heart_Disease	Kategorikal (Biner)	Status diagnosis klinis adanya penyakit jantung.	0: Tidak Ada, 1: Ada
Smoking_Status	Kategorikal	Kategori rekam jejak perilaku	0: Never, 1:

	(Nominal)	merokok pasien.	Formerly, 2: Smokes
Residential_Type	Kategorikal (Biner)	Karakteristik wilayah tempat tinggal pasien.	0: Rural, 1: Urban
SES	Kategorikal (Ordinal)	Socioeconomic Status (Status Sosial Ekonomi).	0: Low, 1: Medium, 2: High
Avg_Glucose_Level	Numerik (Kontinu)	Rata-rata kadar gula di dalam darah (mg/dL).	Angka desimal positif
BMI	Numerik (Kontinu)	Body Mass Index (Indeks Massa Tubuh) dalam kg/m ² .	Angka desimal / NaN
Stroke (Target)	Kategorikal (Biner)	Label manifestasi kejadian stroke aktual (Variabel Target).	0: Tidak, 1: Stroke

2.2 Dokumentasi Struktur Data Citra (Radiologi)

Melengkapi analisis rekam medis, komponen data citra berupa hasil pemindaian CT Scan / MRI aksial kepala distandardisasi dengan regulasi teknis berikut:

- **Standardisasi Dimensi:** Resolusi gambar disamakan menjadi 224 x 224 piksel dengan arsitektur 3-channel warna (RGB) agar siap diproses oleh algoritma ekstraksi fitur spasial Convolutional Neural Network (CNN).
- **Normalisasi Piksel:** Skala nilai matriks warna [0, 255] dikompresi menjadi nilai mengambang [0.0, 1.0] demi mengamankan stabilitas komputasi penurunan gradien.
- **Struktur Pelabelan Folder:** Pemisahan berkas gambar disusun dalam struktur direktori biner yang tegas, memisahkan citra Normal dan citra Stroke (adanya area lesi infark atau perdarahan intraserebral).

BAB 3: EXPLORATORY DATA ANALYSIS & PRAPEMROSESAN DATA

Rubrik Keselarasan: Menilai ketepatan visualisasi data (mudah dipahami), penanganan missing value, imbalance data (SMOTE), dan kebersihan dari Data Leakage (Strict Splitting).

3.1 Penerapan Protokol Strict Splitting

Untuk memastikan pemodelan bebas dari Data Leakage, dataset tabular dipecah terlebih dahulu menjadi 80% Data Latih (8.000 sampel) and 20% Data Uji (2.000 sampel). Langkah krusial seperti pencarian nilai median untuk pengisian data hilang pada BMI serta kalkulasi parameter statistik (mean dan standar deviasi) untuk transformasi StandardScaler hanya merujuk pada subset data latih.

3.2 Penanganan Data Hilang & Keseimbangan Kelas (SMOTE)

Variabel BMI yang memiliki nilai kosong (missing values) diselesaikan dengan metode Median Imputation berbasis data latih. Sementara itu, ketidakseimbangan kelas awal (~70% sehat vs ~30% sakit) dimitigasi secara elegan menggunakan algoritma SMOTE pada subset data latih. Langkah ini berhasil mengamankan keseimbangan kelas target secara presisi menjadi rasio seimbang 5.618 sampel.

BAB 4: EXPLANATORY ANALYSIS & INSIGHT UTAMA

Rubrik Keselarasan: Memberikan jawaban konklusif, insight menarik, grafik yang informatif (berjudul dan berlabel jelas), serta mencakup analisis BMI dan Kadar Glukosa.

Dari visualisasi yang dibangun menggunakan pustaka Seaborn dan Matplotlib dengan anotasi, judul, serta pelabelan sumbu koordinat yang lengkap, diperoleh empat saripati informasi utama:

1. Resolusi Ketidakseimbangan (Menjawab DQ 1):

Pipeline grafik countplot pasca-SMOTE membuktikan distribusi data latih yang seimbang (50% kelas 0 dan 50% kelas 1).

2. Duo Komorbiditas Klinis Tertinggi (Menjawab DQ 2 & 3):

Matriks korelasi (Heatmap) mendedahkan bahwa Usia, Hipertensi, dan Penyakit Jantung memegang koefisien korelasi positif tertinggi.

3. Dampak Faktor Penuaan (Menjawab DQ 3):

Grafik Boxplot menunjukkan sebaran kuartil usia kelompok pasien stroke bergeser jauh ke atas dibanding kelompok sehat.

4. Efek Multiplikatif BMI & Glukosa (Menjawab DQ 4):

Analisis sebaran scatterplot mendeteksi penumpukan klaster stroke padat pada area kadar glukosa darah tinggi dan nilai BMI tinggi, mengonfirmasi risiko berlipat ganda.

BAB 5: KESIMPULAN AKHIR

Berdasarkan seluruh pengujian di atas, struktur berkas [stroke_train_clean - Google Sheets](#) dan [stroke_test_clean.csv](#) dinyatakan memenuhi seluruh kriteria yang dipersyaratkan. Alur analisis terbebas dari kesalahan metodologi data leakage, visualisasi data disajikan dengan komponen label yang informatif, dan seluruh pertanyaan bisnis telah terjawab secara empiris.